

LAPORAN EKSPERIMEN

Dense Retrieval & Embedding Menggunakan FAISS pada Dataset Masjid Indonesia



Mata Kuliah: Advanced Information Retrieval

Dosen Pengampu: Bapak Zico Pratama Putra, S.T., M.Sc., Ph.D

Disusun Oleh Kelompok:

Joharini - 14250008

Farizal Ginanjar - 14250014

Feri Styaheriyanto – 14250005

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi Information Retrieval (IR) telah mengalami perubahan yang sangat pesat. Pada awalnya, sistem pencarian informasi lebih banyak menggunakan pendekatan berbasis pencocokan kata (lexical matching), seperti TF-IDF, Cosine Similarity, dan BM25. Metode tersebut mampu memberikan hasil pencarian yang baik apabila kata kunci yang dimasukkan pengguna memiliki kesamaan dengan isi dokumen. Namun, metode tersebut masih memiliki keterbatasan dalam memahami makna atau hubungan semantik antar kata. Akibatnya, apabila pengguna menggunakan kata yang berbeda tetapi memiliki makna yang sama, sistem sering kali tidak mampu mengembalikan dokumen yang paling relevan.

Seiring berkembangnya teknologi Natural Language Processing (NLP) dan Large Language Model (LLM), pendekatan pencarian informasi mulai beralih menggunakan Dense Retrieval, yaitu metode yang merepresentasikan dokumen dan query ke dalam bentuk embedding vector. Embedding memungkinkan setiap kata, kalimat, maupun dokumen direpresentasikan ke dalam ruang vektor sehingga hubungan semantik antar dokumen dapat dipahami dengan lebih baik dibandingkan metode berbasis kata kunci.

Pada mata kuliah Advanced Information Retrieval, proyek UAS dibagi menjadi beberapa kelompok dengan tahapan pengerjaan yang saling berhubungan. Kelompok 1 bertugas melakukan proses Data Understanding, Data Cleaning, Text Preprocessing, normalisasi data, pembuatan corpus, serta implementasi metode TF-IDF, Cosine Similarity, dan BM25. Hasil akhir dari kelompok tersebut berupa dataset yang telah dibersihkan dan disimpan dalam file `dataset_preprocessed.csv`.

Selanjutnya, Kelompok 2 melanjutkan hasil pekerjaan tersebut dengan fokus pada pembangunan sistem Dense Retrieval menggunakan teknik embedding modern dan Facebook AI Similarity Search (FAISS). Dengan demikian, proses penelitian pada kelompok ini tidak lagi melakukan pembersihan data dari awal, melainkan memanfaatkan dataset hasil preprocessing sebagai dasar untuk membangun sistem pencarian semantik.

Dataset yang digunakan terdiri dari 243.831 data masjid di Indonesia dengan atribut utama seperti nama masjid, alamat, provinsi, kabupaten/kota, kecamatan, jenis masjid, rating, review_count, latitude, dan longitude. Jumlah data yang cukup besar tersebut memerlukan metode pencarian yang efisien agar proses retrieval tetap cepat meskipun jumlah dokumen terus bertambah.

Pada penelitian ini digunakan empat model embedding yang memiliki karakteristik berbeda, yaitu BGE-M3, E5-Large, MPNet, dan MiniLM. Keempat model dipilih karena banyak digunakan dalam berbagai penelitian semantic retrieval serta memiliki ukuran dimensi dan kompleksitas model yang berbeda. Selain itu, penelitian ini juga menggunakan FAISS sebagai struktur indeks vektor yang mampu mempercepat proses pencarian dokumen berdasarkan nilai kemiripan (similarity).

Setelah seluruh embedding berhasil dibangun, dilakukan proses evaluasi menggunakan beberapa query nama masjid untuk membandingkan performa setiap model embedding. Evaluasi dilakukan berdasarkan nilai similarity, waktu pembentukan embedding, dimensi embedding, serta konsistensi model dalam menghasilkan dokumen yang paling relevan.

Melalui eksperimen ini diharapkan dapat diketahui model embedding yang paling sesuai digunakan pada dataset masjid Indonesia sehingga dapat menjadi dasar pengembangan sistem pencarian informasi berbasis semantic search pada penelitian selanjutnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, maka rumusan masalah pada penelitian ini adalah sebagai berikut.

1. Bagaimana membangun sistem Dense Retrieval menggunakan embedding dan FAISS pada dataset masjid Indonesia yang telah diproses oleh Kelompok 1?
2. Bagaimana menghasilkan representasi embedding menggunakan model BGE-M3, E5-Large, MPNet, dan MiniLM pada dataset masjid Indonesia?
3. Bagaimana membangun indeks menggunakan FAISS agar proses pencarian dokumen menjadi lebih cepat dan efisien?
4. Bagaimana membandingkan performa keempat model embedding berdasarkan nilai similarity, dimensi embedding, waktu pembentukan embedding, dan hasil retrieval terhadap query yang diberikan?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Mengimplementasikan sistem Dense Retrieval menggunakan teknik embedding dan FAISS pada dataset masjid Indonesia.
2. Membangun representasi embedding menggunakan empat model embedding modern, yaitu BGE-M3, E5-Large, MPNet, dan MiniLM.

3. Membangun indeks menggunakan FAISS sehingga proses pencarian dokumen menjadi lebih cepat.
4. Membandingkan performa setiap model embedding berdasarkan hasil retrieval yang diperoleh dari beberapa query pengujian.
5. Menentukan model embedding yang memberikan performa terbaik pada dataset masjid Indonesia berdasarkan hasil eksperimen.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut.

1. Manfaat Akademis

- Menambah pemahaman mengenai implementasi Dense Retrieval menggunakan embedding dan FAISS.
- Menjadi referensi bagi mahasiswa yang ingin mempelajari semantic search pada dataset berbahasa Indonesia.
- Memberikan gambaran mengenai perbandingan beberapa model embedding modern pada proses information retrieval.

2. Manfaat Praktis

- Membantu membangun sistem pencarian informasi masjid yang lebih cepat dan relevan.
- Menjadi dasar pengembangan aplikasi pencarian berbasis semantic search.
- Memberikan informasi mengenai model embedding yang paling sesuai digunakan pada dataset masjid Indonesia.

1.5 Ruang Lingkup Penelitian

Agar penelitian lebih terarah, maka ruang lingkup penelitian dibatasi pada beberapa hal berikut.


1. Dataset yang digunakan merupakan hasil preprocessing dari Kelompok 1 dan disimpan dalam file `dataset_preprocessed.csv`.
2. Penelitian tidak membahas proses data cleaning maupun text preprocessing karena tahapan tersebut telah dilakukan pada kelompok sebelumnya.
3. Penelitian hanya berfokus pada implementasi Dense Retrieval menggunakan empat model embedding, yaitu BGE-M3, E5-Large, MPNet, dan MiniLM.

4. Pencarian dokumen dilakukan menggunakan FAISS IndexFlatIP sebagai metode indexing.
5. Evaluasi dilakukan berdasarkan hasil retrieval menggunakan 20 query nama masjid yang telah ditentukan.
6. Parameter evaluasi meliputi dimensi embedding, waktu pembentukan embedding, nilai similarity, serta perbandingan hasil retrieval antar model embedding.
- 7.

METODOLOGI PENELITIAN

2.1 Dataset

Penelitian ini menggunakan dataset masjid Indonesia yang merupakan hasil preprocessing dari Kelompok 1 pada mata kuliah *Advanced Information Retrieval*. Pada tahap sebelumnya telah dilakukan proses *data cleaning*, normalisasi teks, penghapusan data duplikat, serta pembentukan corpus sehingga menghasilkan dataset yang siap digunakan untuk proses *Dense Retrieval*. Dataset yang digunakan disimpan dalam file `dataset_preprocessed.csv` dengan jumlah 243.831 dokumen. Setiap dokumen memuat informasi mengenai nama masjid, alamat, provinsi, kabupaten/kota, kecamatan, jenis masjid, rating, jumlah ulasan (*review count*), serta koordinat geografis (latitude dan longitude).



Gambar 2.1. Tahapan Penelitian

2.2 Tahapan Penelitian

Penelitian ini terdiri atas beberapa tahapan utama yang dilakukan secara berurutan, yaitu:

1. Memuat dataset hasil preprocessing dari Kelompok 1.
2. Membangun representasi embedding menggunakan empat model, yaitu BGE-M3, E5-Large, MPNet, dan MiniLM.
3. Menyimpan hasil embedding ke dalam file NumPy (.npy) agar dapat digunakan kembali tanpa melakukan proses embedding ulang.
4. Membangun indeks menggunakan Facebook AI Similarity Search (FAISS) untuk mempercepat proses pencarian dokumen.
5. Melakukan proses *Dense Semantic Search* menggunakan beberapa query nama masjid.
6. Membandingkan performa keempat model embedding berdasarkan nilai similarity, waktu pembentukan embedding, dimensi embedding, dan hasil retrieval.

2.3 Model Embedding

Penelitian ini menggunakan empat model embedding yang memiliki karakteristik berbeda.

- BGE-M3 merupakan model embedding multilingual dengan dimensi 1024 yang dirancang untuk tugas pencarian semantik (*semantic retrieval*).
- E5-Large merupakan model embedding yang dikembangkan untuk meningkatkan kualitas pencarian berbasis representasi semantik dengan dimensi 1024.
- MPNet merupakan model yang menggabungkan keunggulan BERT dan Permuted Language Modeling sehingga menghasilkan embedding berkualitas dengan dimensi 768.
- MiniLM merupakan model embedding yang berukuran lebih kecil dengan dimensi 384 sehingga memiliki proses komputasi yang lebih cepat.

Keempat model tersebut dibandingkan untuk mengetahui model yang paling sesuai digunakan pada dataset masjid Indonesia.

2.4 Pembangunan FAISS Index

Setelah proses embedding selesai, seluruh vektor embedding dinormalisasi menggunakan metode L2 Normalization. Selanjutnya, setiap embedding diindeks menggunakan FAISS IndexFlatIP yang memanfaatkan *Inner Product Similarity* sebagai metode pencarian.

Penggunaan FAISS bertujuan untuk mempercepat proses pencarian dokumen pada dataset yang berukuran besar tanpa harus menghitung kemiripan terhadap seluruh dokumen secara langsung.

2.5 Evaluasi

Evaluasi dilakukan menggunakan 20 query nama masjid yang mewakili berbagai variasi pencarian. Setiap query diuji pada keempat model embedding, kemudian dibandingkan berdasarkan beberapa parameter, yaitu:

- Nilai Similarity Top-1.
- Rata-rata similarity setiap model.
- Waktu pembentukan embedding.
- Dimensi embedding.
- Jumlah query yang berhasil dimenangkan oleh masing-masing model.

Hasil evaluasi tersebut digunakan untuk menentukan model embedding yang memberikan performa terbaik pada proses *Dense Retrieval* untuk dataset masjid Indonesia.

IMPLEMENTASI

3.1 Persiapan Dataset

Tahap pertama pada penelitian ini adalah memuat dataset hasil preprocessing dari Kelompok 1 yang disimpan dalam file `dataset_preprocessed.csv`. Dataset tersebut telah melalui proses pembersihan data sehingga pada penelitian ini tidak dilakukan proses *data cleaning* maupun *text preprocessing* kembali. Dataset terdiri dari 243.831 dokumen dengan atribut utama berupa nama masjid, alamat, provinsi, kabupaten/kota, kecamatan, jenis masjid, rating, jumlah ulasan, serta koordinat lokasi.

	name	address	provinsi	kabko	kecamatan	mosque_type	rating	review_count	latitude	longitude
0	Islamic Center Cihideung	Religious destination · Jl Raya Labuan - Pande...	BANTEN	PANDEGLANG	SUMUR	islamic_center	4.7	15	-6.348019	106.044941
1	Pondok pesantren Nurul Jannah Albantani	Unnamed Road Ujungjaya Kec Sumur Kabupaten Pan...	BANTEN	PANDEGLANG	SUMUR	islamic_center	5.0	3	-6.788132	105.510007
2	Masjid Agung Pandeglang	Pandeglang Pandeglang Regency Banten Indonesia	BANTEN	PANDEGLANG	SUMUR	masjid	4.8	1931	-6.308916	106.104527
3	Pantai Sumur Pandeglang Banten	Tamanjaya Sumur Pandeglang Regency Banten Indo...	BANTEN	PANDEGLANG	SUMUR	langgar	4.5	56	-6.780171	105.503314
4	Posko Dzikrah Sumur Tujuh	Pagerbatu Pandeglang Regency Banten Indonesia	BANTEN	PANDEGLANG	SUMUR	langgar	4.5	4	-6.298109	106.068086

Gambar 3.1. Tampilan Dataset Hasil Preprocessing

Berdasarkan hasil pengamatan, dataset telah memiliki struktur yang baik dan siap digunakan sebagai input pada proses pembentukan embedding.

3.2 Pembentukan Embedding

Pada tahap ini dilakukan proses pembentukan representasi vektor (*embedding*) terhadap seluruh dokumen menggunakan empat model embedding, yaitu BGE-M3, E5-Large, MPNet,

dan MiniLM. Setiap model menghasilkan representasi numerik yang berbeda sesuai dengan arsitektur dan dimensi embedding masing-masing.

Tabel 3.2 Model Embedding

Model	Dimensi	Jumlah Dokumen	Waktu
BGE-M3	1024	243831	116.65
E5-Large	1024	243831	106.69
MPNet	768	243831	52.12
MiniLM	384	243831	35.42

Setelah proses embedding selesai, hasil embedding disimpan dalam format NumPy (.npy) agar dapat digunakan kembali tanpa perlu melakukan proses embedding ulang. Penyimpanan embedding bertujuan untuk menghemat waktu komputasi pada proses eksperimen maupun demonstrasi. Hasil proses embedding menunjukkan bahwa seluruh model berhasil menghasilkan embedding untuk 243.831 dokumen.

3.3 Pembangunan FAISS Index

Embedding yang telah dihasilkan kemudian dinormalisasi menggunakan L2 Normalization sebelum dibangun menjadi indeks menggunakan FAISS IndexFlatIP. Tahap ini bertujuan untuk mempercepat proses pencarian dokumen berdasarkan nilai kemiripan (*similarity*) antar vektor.

Setiap model embedding memiliki satu file indeks FAISS yang disimpan secara terpisah sehingga proses pencarian dapat dilakukan secara langsung tanpa harus membangun indeks kembali.

3.4 Implementasi Dense Semantic Search

Setelah indeks FAISS selesai dibangun, dilakukan implementasi Dense Semantic Search. Pada tahap ini, query yang dimasukkan pengguna terlebih dahulu diubah menjadi embedding menggunakan model yang dipilih. Selanjutnya embedding query dibandingkan dengan seluruh embedding dokumen yang tersimpan pada FAISS untuk memperoleh dokumen dengan nilai similarity tertinggi.

Hasil pencarian menampilkan beberapa informasi penting, yaitu:

- Document ID
- Nama Masjid
- Alamat
- Provinsi

- Kabupaten/Kota
- Kecamatan
- Jenis Masjid
- Rating
- Nilai Similarity
- Ranking hasil pencarian

```
=====
MODEL : MiniLM | QUERY : 'Masjid Istiqlal'
=====
```

	rank	document_ID	query	model	name	address	provinsi	kabko	kecamatan	mosque_type	rating	similarity
0	1	169308	Masjid Istiqlal	MiniLM	Masjid Istiqlal	Tempel Turi Kec Jetis Kabupaten Ponorogo Jawa ...	JAWA TIMUR	PONOROGO	JETIS	masjid	4.3	0.944613
1	2	150489	Masjid Istiqlal	MiniLM	Masjid Istiqlal	Jl Kahuripan Utara Raya Sumber Kec Banjarsari...	JAWA TENGAH	KOTA SURAKARTA	BANJARSARI	masjid	5.0	0.944613
2	3	128777	Masjid Istiqlal	MiniLM	Masjid Istiqlal	Julu Tlogorejo Kec Winong Kabupaten Pati Jawa...	JAWA TENGAH	PATI	WINONG	masjid	48.0	0.944613
3	4	242416	Masjid Istiqlal	MiniLM	Masjid Istiqlal	Mosque · Jl Pandegiling No258	JAWA TIMUR	KOTA SURABAYA	TEGALSARI	masjid	4.8	0.944612
4	5	138439	Masjid Istiqlal	MiniLM	Masjid Istiqlal	Dusun Wenoboyo Wonoboyo Dadapan Cemoro Kec Wo...	JAWA TENGAH	TEMANGGUNG	WONOBOYO	masjid	0.0	0.944612
5	6	121197	Masjid Istiqlal	MiniLM	Masjid Istiqlal	Sokoalas Soka Karangdowo Klaten Regency Centr...	JAWA TENGAH	KLATEN	KARANGDOWO	masjid	46.0	0.944612

Gambar 3.2. Contoh Hasil Dense Semantic Search

Hasil tersebut menunjukkan bahwa sistem mampu menemukan dokumen yang memiliki kemiripan semantik paling tinggi terhadap query yang diberikan.

3.5 Pengujian Multiple Query

Untuk mengetahui konsistensi performa setiap model embedding, dilakukan pengujian menggunakan 20 query nama masjid. Setiap query diuji pada keempat model embedding sehingga dihasilkan empat kelompok hasil retrieval.

Seluruh hasil pengujian kemudian disimpan ke dalam file CSV yang terpisah untuk setiap model embedding. Selain itu, dibuat pula satu tabel perbandingan yang berisi hasil similarity terbaik dari masing-masing model sehingga memudahkan proses analisis pada tahap evaluasi.

3.6 Ringkasan Implementasi

Secara keseluruhan implementasi pada penelitian ini berhasil dilakukan sesuai dengan tahapan yang telah direncanakan. Empat model embedding berhasil membentuk representasi vektor terhadap seluruh dataset, kemudian diindeks menggunakan FAISS sehingga proses *Dense Semantic Search* dapat dilakukan secara efisien. Seluruh hasil eksperimen disimpan dalam bentuk file embedding (.npy), FAISS index (.index), dan CSV untuk mendukung proses evaluasi serta analisis performa setiap model embedding.

EVALUASI DAN ANALISIS HASIL

4.1 Ringkasan Hasil Eksperimen


Pada penelitian ini dilakukan pengujian menggunakan empat model embedding, yaitu BGE-M3, E5-Large, MPNet, dan MiniLM. Seluruh model digunakan untuk membentuk embedding terhadap 243.831 dokumen hasil preprocessing dari Kelompok 1. Selain menghasilkan representasi vektor, penelitian ini juga mengukur waktu pembentukan embedding sebagai salah satu indikator efisiensi komputasi.

Tabel 4.1 Ringkasan Hasil Embedding

Model	Dimensi	Jumlah Dokumen	Waktu Embedding (detik)
BGE-M3	1024	243.831	116,40
E5-Large	1024	243.831	107,21
MPNet	768	243.831	49,57
MiniLM	384	243.831	35,20

Berdasarkan Tabel 4.1, seluruh model berhasil membangun embedding terhadap seluruh dokumen pada dataset. Model BGE-M3 dan E5-Large menghasilkan embedding dengan dimensi terbesar yaitu 1024, sehingga membutuhkan waktu komputasi lebih lama. Sebaliknya, MiniLM memiliki dimensi embedding paling kecil yaitu 384 sehingga menjadi model tercepat dalam proses pembentukan embedding.

4.2 Analisis Waktu Embedding




Gambar 4.1 Perbandingan Waktu Embedding

Grafik pada Gambar 4.1 menunjukkan perbandingan waktu yang dibutuhkan masing-masing model dalam membangun embedding terhadap seluruh dokumen. Terlihat bahwa MiniLM membutuhkan waktu paling singkat, yaitu sekitar 35,20 detik, sedangkan BGE-M3 membutuhkan waktu paling lama yaitu sekitar 116,40 detik.

Perbedaan waktu tersebut dipengaruhi oleh ukuran model dan dimensi embedding yang dihasilkan. Model dengan dimensi lebih besar memerlukan proses komputasi yang lebih kompleks sehingga waktu pembentukan embedding menjadi lebih lama.

4.3 Analisis Dimensi Embedding




Gambar 4.2 Perbandingan Dimensi Embedding

Berdasarkan Gambar 4.2, BGE-M3 dan E5-Large menghasilkan embedding berdimensi 1024, sedangkan MPNet menghasilkan embedding berdimensi 768 dan MiniLM menghasilkan embedding berdimensi 384.

Dimensi embedding menunjukkan banyaknya fitur yang digunakan untuk merepresentasikan makna suatu dokumen. Semakin besar dimensi embedding, semakin kaya informasi semantik yang dapat direpresentasikan, namun kebutuhan komputasi juga meningkat.

4.4 Analisis Similarity Top-1

Untuk mengevaluasi kemampuan setiap model dalam menemukan dokumen yang paling relevan, dilakukan pengujian menggunakan 20 query nama masjid. Setiap query diproses menggunakan keempat model embedding dan dibandingkan berdasarkan nilai Similarity Top-1.




Gambar 4.3 Perbandingan Similarity Top-1

Berdasarkan hasil pengujian, terlihat bahwa setiap model menghasilkan nilai similarity yang berbeda pada setiap query. Pada sebagian besar query, MPNet menghasilkan nilai similarity yang lebih tinggi dibandingkan model lainnya. Namun demikian, terdapat beberapa query tertentu yang menghasilkan nilai similarity tertinggi pada model E5-Large maupun MiniLM. Hal ini menunjukkan bahwa performa model embedding dipengaruhi oleh karakteristik query yang digunakan.

4.5 Analisis Rata-rata Similarity

Untuk memperoleh gambaran performa model secara keseluruhan, dilakukan perhitungan rata-rata nilai Similarity Top-1 dari seluruh query pengujian.



Gambar 4.4 Rata-rata Similarity Top-1

Nilai rata-rata similarity masing-masing model ditunjukkan pada Tabel 4.2.

Tabel 4.2 Rata-rata Similarity Top-1


Model	Rata-rata Similarity
BGE-M3	0,8690
E5-Large	0,9590
MPNet	0,9644
MiniLM	0,9417

Berdasarkan hasil tersebut, MPNet memperoleh rata-rata similarity tertinggi yaitu 0,9644, diikuti oleh E5-Large sebesar 0,9590, kemudian MiniLM sebesar 0,9417, dan BGE-M3 sebesar 0,8690.

Nilai tersebut menunjukkan bahwa MPNet memiliki kemampuan representasi semantik yang lebih baik pada dataset masjid Indonesia sehingga mampu menghasilkan dokumen yang lebih relevan terhadap query yang diberikan.

4.6 Analisis Model Terbaik

Selain menghitung rata-rata similarity, penelitian ini juga menghitung jumlah query yang berhasil dimenangkan oleh masing-masing model berdasarkan nilai similarity tertinggi.



Gambar 4.5 Jumlah Query yang Dimenangkan Tiap Model

Jumlah query yang berhasil dimenangkan oleh setiap model embedding ditunjukkan pada tabel 4.3 berikut ini:

Tabel 4.3 Jumlah Query yang Dimenangkan

Model	Jumlah Query
BGE-M3	0
E5-Large	5
MPNet	13
MiniLM	2

Berdasarkan hasil tersebut, MPNet menjadi model yang paling sering menghasilkan nilai similarity tertinggi, yaitu pada 13 dari 20 query. Sementara itu, E5-Large menjadi model terbaik pada 5 query, dan MiniLM pada 2 query. Pada eksperimen ini BGE-M3 tidak memperoleh nilai similarity tertinggi pada query yang diuji.

Hasil tersebut menunjukkan bahwa MPNet memiliki performa yang paling konsisten dalam proses semantic retrieval pada dataset masjid Indonesia.

4.7 Analisis Keseluruhan

Berdasarkan seluruh hasil eksperimen, setiap model embedding memiliki karakteristik yang berbeda. MiniLM memiliki keunggulan pada kecepatan proses embedding karena menghasilkan dimensi embedding yang lebih kecil. BGE-M3 menghasilkan embedding berdimensi besar, namun pada eksperimen ini belum mampu memberikan nilai similarity tertinggi. E5-Large memberikan performa yang sangat kompetitif dan menjadi model terbaik pada beberapa query tertentu.

Secara keseluruhan, MPNet memberikan keseimbangan terbaik antara kualitas retrieval dan efisiensi komputasi. Model ini memperoleh rata-rata similarity tertinggi, menjadi model terbaik pada sebagian besar query, serta memiliki waktu pembentukan embedding yang relatif lebih cepat dibandingkan BGE-M3 dan E5-Large. Oleh karena itu, berdasarkan hasil eksperimen pada penelitian ini, MPNet dapat direkomendasikan sebagai model embedding yang paling sesuai untuk implementasi Dense Retrieval pada dataset masjid Indonesia.

KESIMPULAN DAN FUTURE WORK

5.1 Kesimpulan

Penelitian ini berhasil mengimplementasikan sistem Dense Retrieval menggunakan empat model embedding, yaitu BGE-M3, E5-Large, MPNet, dan MiniLM pada dataset masjid Indonesia yang telah diproses oleh Kelompok 1. Seluruh proses dimulai dari pembentukan embedding, pembangunan indeks menggunakan Facebook AI Similarity Search (FAISS), hingga implementasi *Dense Semantic Search* menggunakan beberapa query nama masjid.

Berdasarkan hasil eksperimen terhadap 243.831 dokumen dan 20 query pengujian, seluruh model embedding berhasil menghasilkan representasi vektor dan dapat digunakan untuk melakukan pencarian semantik. Hasil pengujian menunjukkan bahwa setiap model memiliki karakteristik yang berbeda dalam hal kualitas retrieval maupun efisiensi komputasi.

Model MPNet memperoleh performa terbaik pada eksperimen ini dengan rata-rata similarity sebesar 0,9644 dan menjadi model terbaik pada 13 dari 20 query yang diuji. Hasil tersebut menunjukkan bahwa MPNet mampu menghasilkan representasi semantik yang lebih baik sehingga dokumen yang ditemukan memiliki tingkat relevansi yang tinggi terhadap query yang diberikan.

Model E5-Large juga memberikan performa yang kompetitif dengan rata-rata similarity sebesar 0,9590 dan menjadi model terbaik pada 5 query. Sementara itu, MiniLM memiliki keunggulan dari sisi efisiensi karena menghasilkan waktu pembentukan embedding paling cepat, yaitu sekitar 35,20 detik, meskipun nilai similarity yang diperoleh masih berada di bawah MPNet dan E5-Large. Pada eksperimen ini, BGE-M3 belum memperoleh nilai similarity tertinggi pada query yang diuji, namun tetap mampu menghasilkan representasi embedding yang baik.

Berdasarkan keseluruhan hasil eksperimen, dapat disimpulkan bahwa MPNet merupakan model yang paling seimbang pada dataset masjid Indonesia karena mampu memberikan kualitas retrieval yang tinggi dengan waktu komputasi yang relatif efisien. Dengan demikian, tujuan penelitian untuk membangun dan membandingkan sistem Dense Retrieval menggunakan beberapa model embedding modern telah berhasil dicapai.

5.2 Future Work

Penelitian ini masih memiliki beberapa keterbatasan yang dapat dikembangkan pada penelitian selanjutnya. Oleh karena itu, beberapa pengembangan yang dapat dilakukan antara lain:

1. Menambah jumlah query pengujian sehingga evaluasi model embedding menjadi lebih komprehensif dan mampu menggambarkan performa model pada berbagai variasi pencarian.
2. Menggunakan dataset yang lebih besar dan lebih beragam, misalnya mencakup data masjid yang diperbarui secara berkala atau data tempat ibadah lainnya, sehingga model dapat diuji pada kondisi yang lebih kompleks.
3. Membandingkan model embedding terbaru, seperti NV-Embed, Jina Embeddings, GTE, atau model multilingual generasi terbaru untuk mengetahui peningkatan kualitas semantic retrieval.
4. Mengintegrasikan tahap re-ranking menggunakan Cross Encoder setelah proses FAISS retrieval. Pendekatan ini dapat meningkatkan akurasi hasil pencarian karena dokumen yang telah ditemukan oleh FAISS akan dievaluasi kembali menggunakan model yang lebih presisi.
5. Mengembangkan aplikasi Semantic Search berbasis web atau mobile, sehingga sistem yang telah dibangun tidak hanya menjadi eksperimen akademik, tetapi juga dapat dimanfaatkan sebagai aplikasi pencarian informasi masjid secara nyata.
6. Menambahkan evaluasi menggunakan metrik Information Retrieval, seperti Recall@K, Precision@K, Mean Reciprocal Rank (MRR), dan Normalized Discounted Cumulative Gain (NDCG). Pada proyek ini evaluasi berfokus pada nilai similarity dan perbandingan antar model, sedangkan metrik-metrik tersebut dapat memberikan gambaran yang lebih lengkap mengenai kualitas sistem retrieval.

Kalimat Penutup

Sebagai penutup, penelitian ini menunjukkan bahwa penerapan Dense Retrieval berbasis embedding dan FAISS mampu meningkatkan kemampuan sistem dalam memahami hubungan semantik antara query dan dokumen. Hasil eksperimen menunjukkan bahwa pemilihan model embedding sangat memengaruhi kualitas retrieval dan efisiensi komputasi. Oleh karena itu, pemilihan model yang sesuai dengan karakteristik dataset menjadi faktor penting dalam pembangunan sistem Semantic Search yang akurat, cepat, dan efisien.

REFERENCES

[1], [2], [3], [4][5]

- [1] W. Chen, X. Ma, J. Zeng, Y. Duan, and G. Zhong, "Hierarchical quantization for billion-scale similarity retrieval on GPUs," *Comput. Electr. Eng.*, vol. 90, Mar. 2021, doi: 10.1016/j.compeleceng.2021.107002.
- [2] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation." [Online]. Available: <https://github.com/FlagOpen/FlagEmbedding>.
- [3] K. Song, X. Tan, T. Qin, J. Lu, and T.-Y. Liu, "MPNet: Masked and Permuted Pre-training for Language Understanding." [Online]. Available: <https://github.com/microsoft/MPNet>.
- [4] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, "MINILM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," *Adv. Neural Inf. Process. Syst.*, vol. 2020-December, 2020.
- [5] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using siamese BERT-networks," *EMNLP-IJCNLP 2019 - 2019 Conf. Empir. Methods Nat. Lang. Process. 9th Int. Jt. Conf. Nat. Lang. Process. Proc. Conf.*, pp. 3982–3992, 2019, doi: 10.18653/v1/D19-1410.