

LAPORAN EKSPERIMEN

Dense Retrieval & Embedding Menggunakan FAISS pada Dataset Masjid Indonesia



Mata Kuliah: Advanced Information Retrieval

Dosen Pengampu: Bapak Zico Pratama Putra, S.T., M.Sc., Ph.D

Disusun Oleh Kelompok:

Joharini - 14250008

Farizal Ginanjar - 14250014

Feri Stya Heriyanto – 14250005

BAGIAN 1

PENDAHULUAN

1.1 Latar Belakang

Perkembangan Information Retrieval saat ini tidak hanya mengandalkan pencarian berdasarkan kesamaan kata (keyword matching), tetapi juga mulai memanfaatkan representasi semantik menggunakan teknik embedding. Dengan adanya embedding, sistem pencarian dapat memahami hubungan makna antar kata sehingga hasil pencarian menjadi lebih relevan dibandingkan metode pencarian tradisional.

Pada mata kuliah **Advanced Information Retrieval**, kami diberikan sebuah dataset masjid Indonesia oleh dosen kami yaitu Bapak Zico, dimana datasetnya masih dalam bentuk **data mentah (raw dataset)** yang berasal dari aplikasi iMosque. Dataset tersebut masih terdiri dari banyak file, memiliki atribut yang beragam, terdapat data yang tidak lengkap (missing value), data duplikat, serta format penulisan yang belum seragam. Oleh karena itu, sebelum digunakan untuk proses Dense Retrieval, dataset harus dipersiapkan dan dibersihkan terlebih dahulu agar dapat digunakan sebagai corpus pencarian.

Pada proyek ini, proses awal seperti penggabungan dataset, analisis data, pembersihan data, serta pembuatan corpus dilakukan bersama sebagai bagian dari pekerjaan kelompok. Selanjutnya, **Kelompok 2** melanjutkan proses tersebut dengan membuat dan menyimpan **corpus_clean** untuk membangun sistem **Dense Retrieval** menggunakan beberapa model embedding berbasis Transformer yang dikombinasikan dengan **Facebook AI Similarity Search (FAISS)** sebagai media penyimpanan dan pencarian vector embedding.

Melalui eksperimen ini kami ingin mengetahui bagaimana perbedaan performa beberapa model embedding dalam melakukan pencarian semantik terhadap data masjid Indonesia serta melihat model mana yang memberikan hasil pencarian yang paling relevan berdasarkan nilai similarity.

1.2 Permasalahan

Berdasarkan dataset yang diberikan oleh dosen, terdapat beberapa permasalahan yang harus diselesaikan sebelum proses Dense Retrieval dilakukan, yaitu:

1. Dataset masih berupa data mentah sehingga perlu dilakukan proses pembersihan dan normalisasi data.
2. Terdapat missing value pada beberapa atribut, terutama pada kolom alamat (address).
3. Penulisan nama masjid dan atribut lainnya belum seragam sehingga diperlukan proses text preprocessing.

4. Belum diketahui model embedding mana yang memberikan hasil semantic retrieval terbaik pada dataset masjid Indonesia.
5. Diperlukan mekanisme pencarian yang mampu mencari berdasarkan makna (semantic search), bukan hanya berdasarkan kecocokan kata.

1.3 Tujuan Proyek

Tujuan dari proyek ini adalah:

1. Mempersiapkan dataset hasil preprocessing menjadi corpus yang siap digunakan pada proses Dense Retrieval.
2. Membangun vector embedding menggunakan empat model embedding yang berbeda.
3. Membangun FAISS Index untuk mempercepat proses pencarian vector.
4. Mengimplementasikan Dense Semantic Retrieval pada dataset masjid Indonesia.
5. Membandingkan performa empat model embedding berdasarkan hasil retrieval, nilai similarity, dimensi embedding, dan waktu proses embedding.

1.4 Ruang Lingkup

Pada proyek ini ruang lingkup penelitian dibatasi pada beberapa hal berikut.

- Dataset yang digunakan merupakan dataset masjid Indonesia yang diberikan oleh dosen pada mata kuliah Advanced Information Retrieval.
- Data yang digunakan merupakan hasil preprocessing dari dataset mentah yang telah dibersihkan sebelum proses embedding dilakukan.
- Model embedding yang digunakan terdiri dari empat model, yaitu:
 - BGE-M3
 - E5-Large
 - MPNet
 - MiniLM
- Metode indexing menggunakan FAISS dengan **IndexFlatIP** dan normalisasi **Cosine Similarity**.
- Query yang digunakan merupakan nama masjid sebagai pengujian semantic retrieval.

1.5 Kontribusi Kelompok

Pada proyek ini, pekerjaan dilakukan secara bertahap sesuai pembagian tugas yang telah disepakati. Tahap awal dimulai dari proses memahami dataset mentah yang diberikan oleh dosen. Dataset tersebut kemudian dipelajari untuk mengetahui struktur data, atribut yang tersedia, serta permasalahan yang terdapat di dalamnya. Setelah itu dilakukan proses pembersihan data seperti pengecekan missing value, penghapusan data duplikat, normalisasi

teks, serta penyusunan corpus yang nantinya digunakan sebagai dasar pada proses Dense Retrieval.

Setelah corpus berhasil dibuat, **Kelompok 2** bertanggung jawab mengimplementasikan proses Dense Retrieval menggunakan empat model embedding yang berbeda, membangun FAISS Index, melakukan proses semantic search, serta membandingkan hasil retrieval dari masing-masing model berdasarkan beberapa query yang telah ditentukan.

Melalui pembagian tugas tersebut, setiap tahapan proyek saling berkaitan sehingga menghasilkan sebuah sistem pencarian semantik yang dapat digunakan untuk melakukan pencarian data masjid Indonesia secara lebih relevan.

BAB II

METODOLOGI


2.1 Metode Penelitian

Pada proyek ini digunakan metode eksperimen untuk membangun sistem **Dense Retrieval** menggunakan empat model embedding berbasis Transformer. Eksperimen dilakukan dengan membandingkan hasil pencarian semantic dari setiap model embedding menggunakan dataset masjid Indonesia yang telah melalui proses preprocessing.

Tahapan penelitian dimulai dari mempersiapkan dataset, membangun corpus, menghasilkan vector embedding, membangun FAISS Index, kemudian melakukan semantic retrieval menggunakan beberapa query yang telah ditentukan. Hasil dari setiap model kemudian dibandingkan berdasarkan nilai similarity, dimensi embedding, waktu proses embedding, dan kualitas hasil retrieval.

2.2 Alur Penelitian

Alur penelitian pada proyek ini dapat dijelaskan sebagai berikut.



2.3 Dataset

Dataset yang digunakan pada penelitian ini merupakan dataset masjid Indonesia yang diberikan oleh dosen mata kuliah **Advanced Information Retrieval**. Dataset berasal dari aplikasi iMosque dan masih berupa data mentah yang terdiri dari beberapa file sehingga perlu dilakukan proses penggabungan dan pembersihan data sebelum digunakan.

Setelah proses preprocessing selesai dilakukan, diperoleh dataset akhir sebanyak **243.576 dokumen** yang siap digunakan sebagai corpus pada proses Dense Retrieval.

Atribut yang digunakan pada penelitian ini meliputi:

No	Atribut	Keterangan
1	name	Nama masjid
2	address	Alamat
3	provinsi	Provinsi
4	kabko	Kabupaten/Kota
5	kecamatan	Kecamatan
6	mosque_type	Jenis tempat ibadah
7	latitude	Koordinat lintang
8	longitude	Koordinat bujur

Pada proses embedding, penelitian ini menggunakan **kolom name** sebagai representasi dokumen. Kolom lainnya tetap dipertahankan sebagai informasi tambahan yang ditampilkan pada hasil pencarian.

2.4 Data Cleaning

Sebelum digunakan pada proses embedding, dataset terlebih dahulu dibersihkan untuk meningkatkan kualitas data. Tahapan data cleaning meliputi:

1. Pemeriksaan Missing Value

Dilakukan pengecekan missing value pada seluruh atribut yang digunakan. Kolom **address** memiliki beberapa nilai kosong sehingga dilakukan pengisian menggunakan teks "*Alamat tidak tersedia*" agar proses selanjutnya tidak mengalami error.

2. Pemeriksaan Data Duplikat

Dilakukan pengecekan terhadap data duplikat menggunakan fungsi pandas. Data yang tidak diperlukan dihapus sehingga setiap dokumen yang digunakan memiliki informasi yang unik.

3. Text Cleaning

Seluruh teks dibersihkan menggunakan fungsi `clean_text()` dengan tahapan sebagai berikut.

- Mengubah seluruh huruf menjadi huruf kecil (lowercase).
- Menghapus URL.
- Menghapus tanda baca.
- Menghapus karakter khusus.

- Menghapus spasi berlebih.
- Menghapus spasi di awal dan akhir kalimat.

Contoh hasil preprocessing ditunjukkan pada Tabel berikut.

Sebelum	Sesudah
Masjid Agung Demak	masjid agung demak
Jl. Raya Pandeglang No.10	jl raya pandeglang no 10

2.5 Corpus

Setelah proses preprocessing selesai dilakukan, seluruh data disimpan menjadi file **corpus_clean.csv**. Corpus merupakan kumpulan dokumen yang akan digunakan sebagai input pada proses embedding. Pada penelitian ini, setiap dokumen direpresentasikan menggunakan **nama masjid** yang telah melalui proses preprocessing.

Contoh corpus:

```
"Masjid Raya Baiturrahman",
"Masjid Agung Demak",
"Masjid Al Jabbar",
"Masjid Jami"
```

Penggunaan kolom **name** dipilih karena tujuan utama penelitian adalah melakukan pencarian berdasarkan nama masjid sehingga representasi dokumen menjadi lebih sederhana dan menghasilkan retrieval yang lebih fokus.

2.6 Model Embedding

Penelitian ini menggunakan empat model embedding berbasis Transformer untuk dibandingkan performanya.

Model	Dimensi
BGE-M3	1024
E5-Large	1024
MPNet	768
MiniLM	384

Keempat model digunakan untuk mengubah setiap dokumen menjadi vector embedding sehingga dapat dilakukan pencarian berdasarkan kemiripan semantik.

2.7 Generate Embedding

Pada tahap ini seluruh corpus diubah menjadi vector embedding menggunakan masing-masing model. Proses dilakukan menggunakan library **SentenceTransformer** dengan parameter `convert_to_numpy=True` sehingga hasil embedding dapat langsung digunakan oleh FAISS.

Output dari proses ini berupa matriks embedding dengan ukuran:

```
(jumlah_dokumen × dimensi_embedding)
```

Contohnya:

BGE-M3

```
(243576, 1024)
```

MiniLM

```
(243576, 384)
```

2.8 Pembangunan FAISS Index

Setelah seluruh embedding berhasil dibuat, dilakukan pembangunan **FAISS Index** menggunakan metode **IndexFlatIP**.

Sebelum proses indexing dilakukan, seluruh vector embedding dinormalisasi menggunakan **L2 Normalization** sehingga perhitungan **Inner Product** dapat digunakan sebagai **Cosine Similarity**.

Hasil dari tahap ini adalah file indeks dengan format:

1. BGE_M3.index
2. E5_Large.index
3. MPNet.index
4. MiniLM.index

2.9 Dense Semantic Retrieval

Tahap terakhir pada implementasi adalah membangun fungsi **Dense Semantic Search**.

Proses pencarian dilakukan dengan langkah-langkah berikut.

1. Pengguna memasukkan query.
2. Query diubah menjadi embedding menggunakan model yang sama.
3. Query embedding dinormalisasi menggunakan L2 Normalization.
4. FAISS mencari vector yang memiliki similarity tertinggi.
5. Sistem menampilkan Top-K dokumen yang paling relevan beserta nilai similarity.

Pada penelitian ini dilakukan dua jenis pengujian, yaitu:

- **Single Query**, menggunakan satu query seperti *Masjid Istiqlal*.
- **Multiple Query**, menggunakan beberapa query seperti *Masjid Raya Baiturrahman*, *Masjid Agung Demak*, *Masjid Al Jabbar*, dan *Masjid Jami*.

BAB III

IMPLEMENTASI

3.1 Persiapan Eksperimen

Implementasi sistem dilakukan menggunakan **Google Colaboratory (Google Colab)** sebagai lingkungan pengembangan. Seluruh proses mulai dari pembacaan dataset, preprocessing, pembentukan embedding, pembangunan FAISS Index, hingga pengujian semantic retrieval dilakukan menggunakan bahasa pemrograman Python.

Spesifikasi perangkat lunak yang digunakan adalah sebagai berikut.

Komponen	Keterangan
Bahasa Pemrograman Python 3	
Platform	Google Colab
Library	Pandas, NumPy, SentenceTransformers, FAISS, Matplotlib
Dataset	Dataset Masjid Indonesia (iMosque)
Jumlah Dokumen	243.576 (corpus_clean)

3.2 Persiapan Dataset

Tahap pertama implementasi dimulai dengan membaca dataset hasil preprocessing yang telah disimpan dalam file **corpus_clean.csv**. Dataset tersebut merupakan hasil pembersihan data yang dilakukan pada tahap sebelumnya sehingga siap digunakan sebagai corpus pada proses Dense Retrieval.

Dataset yang digunakan memiliki delapan atribut utama, yaitu nama masjid, alamat, provinsi, kabupaten/kota, kecamatan, jenis tempat ibadah, serta koordinat lokasi. Setelah dataset berhasil dibaca, dilakukan pengecekan kembali jumlah dokumen, jumlah kolom, serta validasi missing value untuk memastikan bahwa data siap digunakan pada proses selanjutnya.

3.3 Pemilihan Model Embedding

Pada penelitian ini digunakan empat model embedding berbasis Transformer yang memiliki karakteristik berbeda.

Model	Dimensi Embedding
BGE-M3	1024
E5-Large	1024
MPNet	768
MiniLM	384

Keempat model tersebut dipilih untuk dibandingkan performanya dalam menghasilkan vector embedding dan melakukan semantic retrieval pada dataset masjid Indonesia.

3.4 Pembuatan Dokumen (Corpus)

Setelah dataset berhasil dibaca, dilakukan proses pembentukan dokumen yang akan digunakan sebagai input model embedding. Pada penelitian ini setiap dokumen direpresentasikan menggunakan **kolom nama masjid (name)** yang telah melalui proses preprocessing.

Contoh dokumen setelah preprocessing adalah sebagai berikut.

Data Asli	Setelah Preprocessing
Masjid Istiqlal	masjid istiqlal
Masjid Raya Baiturrahman	masjid raya baiturrahman
Masjid Agung Demak	masjid agung demak

Pemilihan kolom **name** dilakukan karena tujuan utama sistem adalah melakukan pencarian berdasarkan nama masjid sehingga hasil retrieval menjadi lebih fokus dan relevan.

3.5 Generate Dense Embedding

Tahap berikutnya adalah mengubah seluruh dokumen menjadi vector embedding menggunakan masing-masing model. Setiap model membaca seluruh corpus kemudian menghasilkan representasi numerik berupa vector embedding yang memiliki dimensi berbeda sesuai dengan arsitektur model.

Sebagai contoh, model **BGE-M3** menghasilkan embedding berdimensi **1024**, sedangkan **MiniLM** menghasilkan embedding berdimensi **384**. Seluruh embedding kemudian disimpan ke dalam dictionary agar dapat digunakan kembali pada proses indexing maupun retrieval.

Selain menghasilkan vector embedding, sistem juga mencatat waktu yang dibutuhkan oleh masing-masing model untuk melakukan proses embedding.

3.6 Ringkasan Hasil Embedding

Setelah proses embedding selesai dilakukan, sistem menampilkan ringkasan hasil embedding yang berisi informasi mengenai jumlah vector, dimensi embedding, dan waktu proses embedding.

Tabel 3.1 Ringkasan Hasil Embedding

Model	Dimensi	Jumlah Vector	Waktu (detik)
BGE-M3	1024	243576	184.63
E5-Large	1024	243576	183.18
MPNet	768	243576	100.88
MiniLM	384	243576	93.61

Berdasarkan hasil tersebut terlihat bahwa seluruh model berhasil menghasilkan embedding untuk seluruh dokumen pada dataset. Model MiniLM membutuhkan waktu paling singkat, sedangkan BGE-M3 dan E5-Large memerlukan waktu yang lebih lama karena menghasilkan embedding dengan dimensi yang lebih besar.

3.7 Penyimpanan Embedding

Setelah seluruh vector embedding berhasil dibuat, embedding masing-masing model disimpan ke dalam file berekstensi **.npy**. Penyimpanan embedding bertujuan agar proses embedding tidak perlu diulang setiap kali sistem dijalankan sehingga waktu komputasi menjadi lebih efisien.

File yang dihasilkan antara lain:

1. BGE_M3_embeddings.npy
2. E5_Large_embeddings.npy
3. MPNet_embeddings.npy
4. MiniLM_embeddings.npy

3.8 Pembangunan FAISS Index

Tahap berikutnya adalah membangun **FAISS Index** dari seluruh vector embedding. Sebelum proses indexing dilakukan, seluruh embedding dinormalisasi menggunakan **L2 Normalization** sehingga perhitungan **Inner Product** dapat digunakan sebagai **Cosine Similarity**. Setelah proses normalisasi selesai, seluruh embedding dimasukkan ke dalam **IndexFlatIP** untuk membentuk vector index. Proses ini dilakukan pada keempat model sehingga masing-masing model memiliki FAISS Index sendiri.

3.9 Penyimpanan FAISS Index

FAISS Index yang telah berhasil dibangun kemudian disimpan dalam file berekstensi **.index**. Penyimpanan index bertujuan agar proses pencarian dapat dilakukan kembali tanpa harus membangun index dari awal.

File yang dihasilkan terdiri dari:

1. BGE_M3.index
2. E5_Large.index
3. MPNet.index
4. MiniLM.index

3.10 Implementasi Dense Semantic Search

Setelah embedding dan FAISS Index selesai dibuat, tahap selanjutnya adalah membangun fungsi **Dense Semantic Search**. Fungsi ini bertugas mengubah query pengguna menjadi embedding, melakukan pencarian pada FAISS Index, kemudian mengembalikan beberapa dokumen yang memiliki nilai similarity tertinggi.

Informasi yang ditampilkan pada hasil pencarian meliputi:

1. Nama Masjid
2. Alamat
3. Provinsi
4. Kabupaten/Kota
5. Kecamatan
6. Nilai Similarity

3.11 Implementasi Pengujian

Untuk mengetahui performa setiap model embedding dilakukan dua jenis pengujian.

1. Pengujian Single Query

Pada tahap ini sistem melakukan pencarian menggunakan satu query, yaitu:

- Masjid Istiqlal

Pengujian ini bertujuan untuk melihat apakah setiap model mampu menemukan dokumen yang memiliki nama masjid yang sama atau memiliki kemiripan semantik dengan query yang diberikan.

2. Pengujian Multiple Query

Selain pengujian single query, dilakukan pula pengujian menggunakan beberapa query yang berbeda, yaitu:

- Masjid Raya Baiturrahman
- Masjid Agung Demak
- Masjid Al Jabbar
- Masjid Jami

Pengujian ini bertujuan untuk melihat konsistensi performa masing-masing model embedding dalam menemukan dokumen yang relevan pada berbagai jenis nama masjid.

BAB IV

EVALUASI DAN ANALISIS HASIL

4.1 Tujuan Evaluasi

Tahap evaluasi dilakukan untuk mengetahui kemampuan masing-masing model embedding dalam melakukan **Dense Semantic Retrieval** pada dataset masjid Indonesia. Evaluasi difokuskan pada kemampuan model dalam menemukan dokumen yang relevan terhadap query yang diberikan serta membandingkan performa setiap model berdasarkan waktu proses embedding, dimensi embedding, dan nilai similarity.


Pada penelitian ini digunakan empat model embedding, yaitu **BGE-M3**, **E5-Large**, **MPNet**, dan **MiniLM**. Seluruh model diuji menggunakan dataset yang sama sehingga hasil yang diperoleh dapat dibandingkan secara langsung.

4.2 Hasil Proses Embedding

Setelah seluruh corpus berhasil diproses, masing-masing model menghasilkan vector embedding dengan dimensi yang berbeda. Selain itu, waktu yang dibutuhkan setiap model dalam menghasilkan embedding juga dicatat sebagai salah satu parameter evaluasi.

Tabel 4.1 Hasil Proses Embedding

Model	Dimensi Embedding	Jumlah Dokumen	Waktu Embedding (detik)
BGE-M3	1024	243.576	184,63
E5-Large	1024	243.576	183,18
MPNet	768	243.576	100,88
MiniLM	384	243.576	93,61




Gambar 4.1 Perbandingan Waktu Embedding

Berdasarkan Tabel dan Gambar 4.1 terlihat bahwa seluruh model berhasil menghasilkan embedding untuk **243.576 dokumen** tanpa mengalami kegagalan. Perbedaan utama terletak pada dimensi embedding dan waktu komputasi. Model **BGE-M3** dan **E5-Large** memiliki dimensi embedding paling besar, yaitu **1024**, sehingga membutuhkan waktu proses yang lebih lama dibandingkan model lainnya. Sebaliknya, **MiniLM** memiliki dimensi paling kecil yaitu **384** sehingga mampu menghasilkan embedding dengan waktu tercepat.

4.2 Analisis Dimensi Embedding

Pada bagian ini jelaskan perbedaan dimensi masing-masing model.




Gambar 4.2 Perbandingan Dimensi Embedding

Gambar 4.2 menunjukkan bahwa BGE-M3 dan E5-Large menghasilkan embedding berdimensi 1024, MPNet berdimensi 768, sedangkan MiniLM hanya 384. Perbedaan dimensi ini memengaruhi kebutuhan memori dan waktu komputasi.

4.3 Evaluasi Single Query

Pengujian pertama dilakukan menggunakan satu query yaitu "**Masjid Istiqlal**". Tujuan pengujian ini adalah untuk melihat kemampuan masing-masing model dalam menemukan dokumen yang memiliki kemiripan semantik dengan query yang diberikan.



Gambar 4.1 Hasil Single Query "Masjid Istiqlal"

Berdasarkan hasil pengujian, seluruh model berhasil menemukan dokumen yang memiliki nama **Masjid Istiqlal**. Namun demikian, urutan hasil pencarian dan nilai similarity yang diperoleh berbeda pada setiap model. Model **MPNet** menghasilkan nilai similarity paling tinggi sehingga menunjukkan bahwa model ini mampu merepresentasikan hubungan semantik dengan lebih baik pada query yang diberikan. Model **E5-Large** juga memberikan hasil yang sangat baik dengan nilai similarity yang mendekati MPNet. Sementara itu, **BGE-M3** menghasilkan hasil pencarian yang stabil walaupun nilai similarity lebih rendah. Model **MiniLM** juga mampu menemukan dokumen yang relevan, namun nilai similarity yang dihasilkan sedikit lebih rendah dibandingkan model lainnya.

4.4 Evaluasi Multiple Query

Selain menggunakan satu query, dilakukan pula pengujian menggunakan beberapa query yang berbeda untuk mengetahui konsistensi masing-masing model dalam melakukan semantic retrieval.


Query yang digunakan meliputi:

- Masjid Raya Baiturrahman
- Masjid Agung Demak
- Masjid Al Jabbar
- Masjid Jami

Pengujian dilakukan terhadap keempat model embedding menggunakan jumlah hasil pencarian sebanyak lima dokumen terbaik (Top-5).

Tabel 4.2 Hasil Similarity Setiap Query


Query	BGE-M3	E5-Large	MPNet	MiniLM
Masjid Raya Baiturrahman	0.9151	0.9697	0.9734	0.9588
Masjid Agung Demak	0.8372	0.9551	0.9594	0.9210
Masjid Al Jabbar	0.9117	0.9600	0.9891	0.9392
Masjid Jami	0.8825	0.9647	0.9681	0.9061



Gambar 4.3 Perbandingan Similarity Empat Model

Berdasarkan Gambar 4.3 terlihat bahwa MPNet memperoleh nilai similarity tertinggi pada hampir seluruh query, sedangkan E5-Large menunjukkan performa yang lebih konsisten dalam mengembalikan dokumen yang relevan.

4.5 Analisis Performa Model



Gambar 4.4 Rata-rata Similarity Seluruh Query

Tabel 4.3 Rata-rata Similarity

Ranking	Model	Average Similarity
1	MPNet	0.9725
2	E5-Large	0.9624
3	MiniLM	0.9313
4	BGE-M3	0.8866

Berdasarkan rata-rata similarity, MPNet memperoleh nilai tertinggi sebesar 0,9725. Namun, pada beberapa query seperti "Masjid Agung Demak", E5-Large memberikan hasil yang lebih relevan meskipun nilai similarity sedikit lebih rendah. Hal ini menunjukkan bahwa evaluasi sistem tidak hanya mempertimbangkan besarnya nilai similarity, tetapi juga ketepatan dokumen yang dikembalikan.

4.5 Perbandingan Model Embedding

Berdasarkan seluruh hasil eksperimen yang telah dilakukan, diperoleh perbandingan sebagai berikut.

Tabel 4.2 Perbandingan Model Embedding

Model	Dimensi	Waktu Embedding	Kualitas Retrieval	Kelebihan	Kekurangan
BGE-M3	1024	184,63 detik	Baik	Retrieval stabil	Waktu embedding lebih lama
E5-Large	1024	183,18 detik	Sangat Baik	Similarity tinggi	Dimensi besar sehingga memerlukan memori lebih banyak
MPNet	768	100,88 detik	Sangat Baik	Similarity tertinggi dan retrieval konsisten	Sedikit lebih lambat dibanding MiniLM
MiniLM	384	93,61 detik	Baik	Embedding paling cepat	Similarity lebih rendah dibanding MPNet dan E5-Large

4.6 Analisis Hasil

Berdasarkan seluruh eksperimen yang telah dilakukan, dapat disimpulkan bahwa keempat model berhasil menghasilkan embedding untuk seluruh dataset dan mampu membangun FAISS Index dengan baik. Seluruh model juga berhasil melakukan proses Dense Semantic Retrieval terhadap query yang diberikan.

Perbedaan utama antar model terlihat pada waktu komputasi, dimensi embedding, serta nilai similarity yang dihasilkan. Model **MiniLM** memiliki waktu embedding paling cepat karena menggunakan dimensi embedding yang lebih kecil, sehingga sesuai digunakan pada aplikasi yang membutuhkan proses komputasi ringan. Sebaliknya, **BGE-M3** dan **E5-Large** memerlukan waktu lebih lama karena menghasilkan embedding dengan dimensi yang lebih besar.

Dari sisi kualitas retrieval, **MPNet** memberikan hasil yang paling konsisten pada berbagai query yang diuji. Model ini menghasilkan nilai similarity yang tinggi serta mampu menempatkan dokumen yang relevan pada posisi teratas. **E5-Large** juga menunjukkan performa yang sangat baik dengan hasil yang mendekati MPNet. Sementara itu, **BGE-M3** memberikan hasil yang stabil, sedangkan **MiniLM** tetap mampu melakukan retrieval dengan baik meskipun nilai similarity yang diperoleh lebih rendah.

Secara keseluruhan, hasil eksperimen menunjukkan bahwa pemilihan model embedding memberikan pengaruh terhadap kualitas retrieval dan waktu komputasi. Oleh karena itu, pemilihan model dapat disesuaikan dengan kebutuhan aplikasi. Jika mengutamakan kecepatan, **MiniLM** menjadi pilihan yang baik. Namun, apabila mengutamakan kualitas hasil pencarian, **MPNet** dan **E5-Large** memberikan performa yang lebih baik pada dataset yang digunakan dalam penelitian ini.

BAB V

KESIMPULAN DAN FUTURE WORK

5.1 Kesimpulan

Berdasarkan hasil implementasi dan evaluasi yang telah dilakukan, dapat disimpulkan bahwa sistem **Dense Semantic Retrieval** menggunakan empat model embedding berbasis Transformer berhasil diimplementasikan pada dataset masjid Indonesia. Seluruh tahapan mulai dari preprocessing data, pembentukan corpus, pembuatan embedding, pembangunan FAISS Index, hingga proses semantic retrieval dapat berjalan dengan baik tanpa mengalami kendala yang berarti.

Pada penelitian ini digunakan dataset masjid Indonesia yang telah melalui proses pembersihan data sehingga diperoleh **243.576 dokumen** yang siap digunakan sebagai corpus. Proses preprocessing yang dilakukan meliputi penanganan missing value, normalisasi teks, pembersihan karakter khusus, serta validasi corpus sehingga data menjadi lebih konsisten sebelum digunakan pada proses embedding.

Empat model embedding yang digunakan, yaitu **BGE-M3**, **E5-Large**, **MPNet**, dan **MiniLM**, berhasil menghasilkan vector embedding untuk seluruh dokumen. Seluruh vector embedding kemudian berhasil diindeks menggunakan **FAISS IndexFlatIP** sehingga proses pencarian dokumen dapat dilakukan secara efisien menggunakan pendekatan semantic search.

Hasil pengujian menggunakan beberapa query menunjukkan bahwa seluruh model mampu menemukan dokumen yang relevan terhadap query yang diberikan. Namun demikian, setiap model memiliki karakteristik yang berbeda. **MiniLM** menghasilkan waktu proses embedding tercepat sehingga lebih efisien dari sisi komputasi. Sementara itu, berdasarkan hasil eksperimen pada dataset yang digunakan, **MPNet** menunjukkan hasil retrieval yang paling konsisten dan menghasilkan nilai similarity yang tinggi pada beberapa query yang diuji. **E5-Large** juga memberikan performa yang sangat baik dengan hasil yang mendekati MPNet, sedangkan **BGE-M3** menghasilkan retrieval yang stabil pada seluruh pengujian.

Berdasarkan hasil tersebut dapat disimpulkan bahwa pemilihan model embedding memberikan pengaruh terhadap kualitas retrieval maupun waktu komputasi. Oleh karena itu, pemilihan model dapat disesuaikan dengan kebutuhan aplikasi. Untuk kebutuhan yang mengutamakan efisiensi komputasi, **MiniLM** menjadi pilihan yang baik. Sebaliknya, apabila mengutamakan kualitas hasil pencarian pada dataset yang digunakan dalam penelitian ini, **MPNet** memberikan performa yang paling baik.

5.2 Keterbatasan Penelitian

Meskipun sistem berhasil diimplementasikan, penelitian ini masih memiliki beberapa keterbatasan.

1. Representasi dokumen pada proses embedding hanya menggunakan **kolom nama masjid (name)**, sehingga informasi lain seperti alamat dan wilayah belum dimanfaatkan sebagai bagian dari representasi dokumen.
2. Evaluasi dilakukan menggunakan beberapa query contoh dan membandingkan nilai similarity hasil retrieval. Penelitian ini belum menggunakan metrik evaluasi Information Retrieval seperti **Precision@K**, **Recall@K**, **MRR (Mean Reciprocal Rank)**, atau **NDCG (Normalized Discounted Cumulative Gain)**.
3. FAISS yang digunakan masih menggunakan **IndexFlatIP**, sehingga seluruh vector disimpan secara penuh. Pendekatan ini memberikan hasil yang baik, tetapi kebutuhan memori akan meningkat seiring bertambahnya jumlah dokumen.
4. Dataset yang digunakan berasal dari satu sumber, sehingga hasil penelitian belum dapat digeneralisasi untuk dataset lain dengan karakteristik yang berbeda.

5.3 Future Work

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa pengembangan yang dapat dilakukan pada penelitian selanjutnya.

1. Menambahkan informasi lain seperti **alamat, kabupaten/kota, kecamatan**, dan **provinsi** sebagai representasi dokumen untuk mengetahui pengaruhnya terhadap kualitas semantic retrieval.
2. Menguji model embedding lain yang lebih baru atau lebih besar, seperti **BGE Large**, **GTE**, **Jina Embedding**, atau model embedding multibahasa lainnya, sehingga dapat dibandingkan performanya dengan model yang digunakan pada penelitian ini.
3. Menggunakan metode indexing FAISS yang lebih efisien, seperti **IVF (Inverted File Index)** atau **HNSW (Hierarchical Navigable Small World)**, sehingga proses pencarian dapat dilakukan lebih cepat pada dataset yang lebih besar.

4. Melakukan evaluasi menggunakan metrik standar pada bidang Information Retrieval, seperti **Precision@K**, **Recall@K**, **MRR**, dan **NDCG**, sehingga kualitas retrieval dapat diukur secara lebih objektif.
5. Mengembangkan sistem menjadi aplikasi pencarian masjid berbasis web atau mobile sehingga pengguna dapat melakukan pencarian semantik secara langsung menggunakan antarmuka yang lebih mudah digunakan.

5.4 Penutup

Melalui proyek ini, kami memperoleh pemahaman yang lebih mendalam mengenai penerapan **Dense Retrieval** pada bidang **Information Retrieval**, khususnya dalam penggunaan model embedding berbasis Transformer dan **FAISS** sebagai media pencarian vector. Selain mempelajari implementasi teknis, kami juga memahami pentingnya proses preprocessing, representasi dokumen, dan pemilihan model embedding dalam menghasilkan sistem pencarian yang lebih relevan.

Pengalaman selama mengerjakan proyek ini memberikan wawasan mengenai bagaimana sebuah dataset mentah dipersiapkan hingga menjadi sebuah sistem semantic retrieval yang dapat digunakan untuk mencari informasi secara lebih efektif. Diharapkan hasil proyek ini dapat menjadi dasar untuk pengembangan penelitian selanjutnya pada bidang **Information Retrieval** dan **Semantic Search**.

Daftar Pustaka:

Performance of 4 Pre-Trained Sentence Transformer Models for Semantic Search [1]

- [1] C. Galli, N. Donos, and E. Calciolari, "Performance of 4 Pre-Trained Sentence Transformer Models in the Semantic Query of a Systematic Review Dataset on Peri-Implantitis," *Inf.*, [vol. 15, no. 2, 2024, doi: 10.3390/info15020068](#).

Dense Text Retrieval based on Pretrained Language Models: A Survey [2]

- [2] W. X. Zhao, J. Liu, R. Ren, and J. R. Wen, "Dense Text Retrieval Based on Pretrained Language Models: A Survey," *ACM Trans. Inf. Syst.*, [vol. 42, no. 4, pp. 1–41, 2024, doi: 10.1145/3637870](#).

Implementation of Semantic Search in an Academic Repository Using Sentence-BERT and FAISS [3]

- [3] I. Lubis, H. Lubis, I. N. Wahidah, C. Science, and U. H. Medan, "Implementation of Semantic Search in an Academic Repository Using Sentence-BERT and FAISS," [vol. 10, no. 2, pp. 1060–1069, 2026](#).